

Prédiction des résultats de la phase de groupes de la Coupe du Monde à l'aide du classement Elo et de modèles probabilistes

BOUHARAOU ILYASS

9 juin 2026

Table des matières

1	Introduction	2
1.1	Contexte	2
1.2	Objectifs	2
2	Le classement Elo	2
2.1	Principe	2
2.2	Mise à jour des classements	3
2.3	Utilisation pour la prédiction	3
3	Modélisation des buts par une loi de Poisson	4
3.1	Justification du modèle	4
3.2	Régression de Poisson	4
4	Première approche : modèle de Poisson global	4
5	Deuxième approche : modèle de Poisson avec forces offensives et défensives	5
5.1	Modèle offensif	5
5.2	Modèle défensif	5
5.3	Combinaison des modèles	5
6	Données utilisées	6
6.1	Sources des données	6
6.2	Préparation des données	6
7	Simulation d'un match	6
7.1	Méthode basée sur le classement Elo	6
7.2	Méthode basée sur la loi de Poisson	6
7.3	Méthode de Poisson améliorée	7
8	Simulation de la phase de groupes	7
9	Comparaison des méthodes	7
10	Comparaison des méthodes	7
10.1	Critères d'évaluation	7
10.2	Résultats	8
11	Prédiction de la phase de groupes de la Coupe du Monde 2026	8
12	Conclusion	8

1 Introduction

1.1 Contexte

La prédiction des résultats sportifs constitue un domaine d'étude important en science des données et en statistique. Dans le football, de nombreux facteurs influencent l'issue d'une rencontre, tels que le niveau des équipes ou leur forme récente. Parmi les outils les plus utilisés pour évaluer la force relative des équipes figure le classement Elo, initialement développé pour les échecs puis adapté à de nombreux sports.

Parallèlement, les modèles probabilistes permettent de représenter l'incertitude inhérente aux résultats sportifs. En particulier, la loi de Poisson est fréquemment utilisée pour modéliser le nombre de buts marqués par une équipe au cours d'un match.

Dans ce projet, nous nous intéressons à la prédiction des résultats de la phase de groupes de la Coupe du Monde 2026 en combinant des informations issues du classement Elo et des modèles statistiques adaptés aux scores de football.

1.2 Objectifs

L'objectif principal de ce projet est de développer et d'évaluer plusieurs méthodes de prédiction des résultats des matchs de la phase de groupes d'une Coupe du Monde.

Plus précisément, les objectifs sont les suivants :

- mettre en œuvre un modèle basé uniquement sur le classement Elo ;
- construire un modèle de régression de Poisson permettant d'estimer le nombre de buts marqués par chaque équipe ;
- simuler l'ensemble des rencontres de la phase de groupes à partir des probabilités obtenues ;
- comparer les performances des différentes approches à l'aide de critères quantitatifs de précision ;
- analyser les avantages et les limites de chaque modèle dans le cadre de la prédiction des résultats sportifs.

2 Le classement Elo

2.1 Principe

Le système Elo est une méthode d'évaluation permettant de mesurer la force relative des équipes à partir de leurs résultats passés. Initialement développé par Arpad Elo pour les échecs, il est aujourd'hui largement utilisé dans de nombreux sports, notamment le football.

Chaque équipe est associée à un score numérique appelé *classement Elo*. Plus ce score est élevé, plus l'équipe est considérée comme performante. L'idée fondamentale du système est que la probabilité de victoire d'une équipe dépend uniquement de la différence de classement entre les deux adversaires.

Considérons deux équipes A et B possédant respectivement les classements (R_A) et (R_B) . Le score attendu de l'équipe A est donné par

$$P_A = \frac{1}{1 + 10^{(R_B - R_A)/400}}.$$

De même, le score attendu de l'équipe B vaut

$$P_B = \frac{1}{1 + 10^{(R_A - R_B)/400}}.$$

Ces quantités peuvent être interprétées comme les probabilités théoriques de succès des deux équipes avant le début du match.

Lorsque les deux équipes possèdent le même classement, on obtient

$$P_A = P_B = 0.5.$$

Les deux équipes sont alors considérées comme ayant le même niveau. En revanche, lorsqu'une équipe possède un classement significativement supérieur à celui de son adversaire, sa probabilité de victoire augmente.

Par exemple, si la différence de classement vaut 400 points, alors

$$P_A \approx 0.91,$$

ce qui signifie que l'équipe A est fortement favorite.

2.2 Mise à jour des classements

Après chaque rencontre, les classements Elo sont mis à jour afin de prendre en compte le résultat observé. L'évolution du classement dépend de l'écart entre le résultat réel et le résultat attendu.

On note (S_A) le score obtenu par l'équipe A :

$$S_A = \begin{cases} 1 & \text{si A gagne,} \\ 0.5 & \text{en cas de match nul,} \\ 0 & \text{si A perd.} \end{cases}$$

De manière analogue, le score de l'équipe B est donné par

$$S_B = 1 - S_A.$$

Les nouveaux classements sont alors calculés à l'aide des formules

$$R'_A = R_A + K(S_A - P_A)$$

et

$$R'_B = R_B + K(S_B - P_B),$$

où (K) est un coefficient positif appelé *facteur d'ajustement*.

Ce paramètre contrôle la vitesse d'évolution des classements :

- un (K) élevé rend le classement plus réactif aux résultats récents ;
- un (K) faible produit un classement plus stable.

Le terme ($S_A - P_A$) mesure l'écart entre le résultat observé et le résultat attendu.

Si une équipe réalise une meilleure performance que prévue, alors ($S_A > P_A$) et son classement augmente. À l'inverse, si elle obtient un résultat inférieur aux attentes, son classement diminue.

Ainsi, le système Elo permet de mettre à jour dynamiquement la force estimée des équipes tout en tenant compte de la difficulté des adversaires rencontrés. Battre une équipe très bien classée entraîne un gain de points plus important que battre une équipe moins performante.

2.3 Utilisation pour la prédiction

Dans une première approche, les probabilités obtenues à partir du classement Elo sont utilisées directement pour prédire l'issue des rencontres. Pour chaque match, la probabilité de victoire de chaque équipe est calculée à l'aide de la formule précédente. Un tirage aléatoire permet ensuite de déterminer le résultat simulé du match.

Cette méthode constitue une référence simple et rapide à mettre en œuvre. Les modèles probabilistes étudiés dans la suite du projet seront comparés à cette approche afin d'évaluer l'apport de la modélisation des buts marqués.

3 Modélisation des buts par une loi de Poisson

3.1 Justification du modèle

Dans un match de football, le nombre de buts marqués par une équipe est une variable aléatoire discrète prenant des valeurs entières positives. Les buts étant des événements relativement rares et indépendants sur une courte période, il est naturel de modéliser leur nombre à l'aide d'une loi de Poisson.

On suppose ainsi que le nombre de buts (G) marqués par une équipe suit une loi de Poisson de paramètre (λ) :

$$G \sim \mathcal{P}(\lambda).$$

La probabilité qu'une équipe marque exactement (k) buts est alors donnée par

$$\mathbb{P}(G = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

Le paramètre (λ) représente à la fois l'espérance et la variance du nombre de buts marqués : $\mathbb{E}(G) = \lambda$.

L'objectif principal consiste donc à estimer le paramètre (λ) à partir des informations disponibles sur les équipes.

3.2 Régression de Poisson

Afin d'estimer le nombre moyen de buts marqués, nous utilisons une régression de Poisson. Cette méthode permet de relier le paramètre (λ) à des variables explicatives telles que les classements Elo des équipes.

Dans un modèle de régression de Poisson, le logarithme de l'espérance est supposé dépendre linéairement des variables explicatives :

$$\log(\lambda) = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n.$$

Cette transformation garantit que le paramètre λ reste strictement positif.

Les coefficients du modèle sont estimés par la méthode du maximum de vraisemblance à partir des résultats historiques des matchs internationaux.

4 Première approche : modèle de Poisson global

Dans une première approche, le nombre moyen de buts marqués dépend uniquement du classement Elo de l'équipe et de celui de son adversaire.

Pour chaque observation, on considère :

- le classement Elo de l'équipe ;
- le classement Elo de l'adversaire ;
- le nombre de buts marqués.

Le modèle retenu est

$$\log(\lambda) = \beta_0 + \beta_1 Elo_{\text{équipe}} + \beta_2 Elo_{\text{adversaire}}.$$

Une fois les coefficients estimés, on obtient pour chaque équipe une espérance de buts (λ). Le score d'un match est ensuite simulé à l'aide de deux variables de Poisson indépendantes.

Cette approche présente l'avantage d'être simple à mettre en œuvre mais elle ne tient pas compte des caractéristiques propres à chaque sélection nationale.

5 Deuxième approche : modèle de Poisson avec forces offensives et défensives

Deux équipes possédant un classement Elo similaire peuvent présenter des styles de jeu très différents. Certaines équipes disposent d'une attaque très performante mais d'une défense fragile, tandis que d'autres obtiennent leurs résultats grâce à une organisation défensive solide.

Afin de prendre en compte ces spécificités, nous construisons pour chaque équipe deux modèles distincts :

- un modèle offensif ;
- un modèle défensif.

5.1 Modèle offensif

Pour une équipe (A), le nombre de buts marqués contre un adversaire de classement Elo donné est modélisé par une loi de Poisson de paramètre (μ_A) .

La relation utilisée est

$$\log(\mu_A(Elo_O)) = \alpha_0 + \alpha_1 Elo_O,$$

où Elo_O désigne le classement Elo de l'adversaire.

Les coefficients α_0 et α_1 sont estimés par régression de Poisson à partir des matchs disputés par l'équipe (A).

5.2 Modèle défensif

De manière analogue, on modélise le nombre de buts encaissés par une équipe (B) contre un adversaire de classement Elo donné.

Le paramètre associé est noté ν_B et vérifie

$$\log(\nu_B(Elo_O)) = \beta_0 + \beta_1 Elo_O.$$

Les coefficients β_0 et β_1 sont également estimés par régression de Poisson.

5.3 Combinaison des modèles

Considérons un match opposant les équipes (A) et (B).

Le modèle offensif de (A) fournit une estimation du nombre de buts que l'équipe (A) devrait marquer contre (B) :

$$\mu_A(Elo_B).$$

Le modèle défensif de (B) fournit quant à lui une estimation du nombre de buts que (B) devrait encaisser contre (A) :

$$\nu_B(Elo_A).$$

Afin de combiner ces deux informations, nous définissons

$$\lambda_{A|B} = \frac{\mu_A(Elo_B) + \nu_B(Elo_A)}{2}.$$

De façon symétrique,

$$\lambda_{B|A} = \frac{\mu_B(Elo_A) + \nu_A(Elo_B)}{2}.$$

Les scores du match sont alors simulés à l'aide de deux variables aléatoires indépendantes :

$$G_A \sim \mathcal{P}(\lambda_{A|B})$$

et

$$G_B \sim \mathcal{P}(\lambda_{B|A}).$$

Cette seconde approche permet de distinguer les qualités offensives et défensives des équipes et fournit généralement des prédictions plus réalistes que le modèle global.

6 Données utilisées

6.1 Sources des données

Les résultats historiques des rencontres internationales utilisés pour l'entraînement des modèles proviennent du site World Football Elo Ratings et de la base de données `results.csv` construite à partir de ces informations. Les classements Elo des sélections nationales ont été obtenus à partir du site :

<https://eloratings.net/>

Les résultats historiques des matchs internationaux ont été extraits du dépôt :

https://github.com/martj42/international_results

Ces données ont ensuite été nettoyées et prétraitées avant l'apprentissage des modèles.

6.2 Préparation des données

Les données brutes ont été nettoyées avant l'entraînement des modèles. Les noms des équipes ont été normalisés afin d'assurer la compatibilité entre les résultats historiques et les classements Elo. Les rencontres impliquant des équipes ne disposant pas d'un classement Elo ont été exclues de l'analyse.

Les variables nécessaires aux différents modèles ont ensuite été construites à partir des résultats historiques, notamment les classements Elo des équipes, ceux de leurs adversaires ainsi que les nombres de buts marqués et encaissés.

7 Simulation d'un match

7.1 Méthode basée sur le classement Elo

La première méthode repose uniquement sur le classement Elo des équipes.

Algorithm 1 Simulation d'un match (Elo)

- Entrées : (R_A, R_B)
 - Calcul de la probabilité de victoire : $P(A) = \frac{1}{1+10^{(R_B-R_A)/400}}$
 - Génération d'un nombre aléatoire $u \in [0, 1]$
 - Si $(u < P(A))$ alors A gagne, sinon B gagne
 - Mise à jour des scores Elo : $R'_A = R_A + K(S_A - P_A)$, $R'_B = R_B + K(S_B - P_B)$
-

7.2 Méthode basée sur la loi de Poisson

La deuxième méthode modélise le nombre de buts marqués par chaque équipe.

Algorithm 2 Simulation d'un match (Poisson simple)

- Entrées : (Elo_A, Elo_B)
 - Calcul des paramètres : $\lambda_A = \exp(\alpha_0 + \alpha_1 Elo_A + \alpha_2 Elo_B)$, $\lambda_B = \exp(\alpha_0 + \alpha_1 Elo_B + \alpha_2 Elo_A)$
 - Tirage : $G_A \sim \mathcal{P}(\lambda_A)$, $G_B \sim \mathcal{P}(\lambda_B)$
 - Attribution des points selon le score final
-

7.3 Méthode de Poisson améliorée

Cette méthode introduit une séparation attaque/défense.

Algorithm 3 Simulation d'un match (Poisson amélioré)

- Entrées : équipes (A) et (B)
 - Calcul des intensités : $\lambda_A = \frac{\mu_A(Elo_B) + \nu_B(Elo_A)}{2}$ $\lambda_B = \frac{\mu_B(Elo_A) + \nu_A(Elo_B)}{2}$
 - Tirage : $G_A \sim \mathcal{P}(\lambda_A)$, $G_B \sim \mathcal{P}(\lambda_B)$
 - Attribution des points selon le résultat
-

8 Simulation de la phase de groupes

Pour chaque groupe :

Algorithm 4 Simulation d'un groupe

- Initialisation des points à 0
 - Pour chaque match du groupe :
 - simuler le match avec l'une des méthodes
 - mettre à jour les points
 - Classement final selon les points puis le niveau Elo
-

9 Comparaison des méthodes

10 Comparaison des méthodes

10.1 Critères d'évaluation

Afin de comparer les différentes méthodes de prédiction, trois indicateurs ont été utilisés.

- **Accuracy** : proportion des positions correctement prédites dans les groupes. Une position est considérée comme correcte lorsqu'une équipe est prédite exactement au même rang que dans le classement réel. Si N_c désigne le nombre de positions correctement prédites parmi les $N = 32$ positions de la phase de groupes, alors

$$\text{Accuracy} = \frac{N_c}{N}.$$

- **Erreur moyenne de rang (MAE)** : mesure l'écart moyen entre le rang prédit et le rang réel des équipes. Si r_i est le rang réel de l'équipe i et $\hat{r}_i$ son rang prédit, alors

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |r_i - \hat{r}_i|.$$

Une valeur faible indique que les classements prédits sont proches des classements réels.

- **Taux de qualification** : proportion d'équipes qualifiées pour les huitièmes de finale correctement identifiées. Pour chaque groupe, les deux premières équipes du classement sont considérées comme qualifiées. Si Q_c est le nombre d'équipes qualifiées correctement prédites parmi les $Q = 16$ équipes qualifiées réelles, alors

$$\text{Taux de qualification} = \frac{Q_c}{Q}.$$

Ces indicateurs permettent d'évaluer à la fois la qualité du classement complet des groupes et la capacité du modèle à identifier les équipes qualifiées pour la phase à élimination directe.

Méthode	Accuracy	MAE	Taux de qualification
Elo simple	0.40	0.81	0.56
Poisson	0.34	1	0.50
Poisson amélioré	0.47	0.75	0.75

TABLE 1 – Comparaison des performances des différentes méthodes

10.2 Résultats

On observe que le modèle de Poisson amélioré obtient les meilleures performances globales, avec une accuracy plus élevée et une erreur moyenne (MAE) plus faible que les autres méthodes. Cependant, le critère le plus pertinent dans le cadre de ce problème reste le taux de qualification, car l'objectif principal est d'identifier correctement les équipes accédant à la phase à élimination directe. Sur ce point, le modèle de Poisson amélioré est également le plus performant, ce qui justifie son intérêt pour la prédiction des phases finales de la compétition.

11 Prédiction de la phase de groupes de la Coupe du Monde 2026

À partir des résultats obtenus sur la phase de validation (Coupe du Monde 2022), le modèle de Poisson amélioré est retenu pour effectuer les prédictions finales.

Les groupes de la Coupe du Monde 2026 sont simulés en utilisant les ratings Elo et la modélisation des buts par loi de Poisson. Pour chaque groupe, les équipes sont classées selon leur performance simulée, et les deux premières équipes sont considérées comme qualifiées pour la phase à élimination directe.

Les résultats obtenus sont les suivants :

- **Groupe A** : 'MEXICO', 'SOUTH KOREA', 'CZECH REPUBLIC', 'SOUTH AFRICA'
- **Groupe B** : 'CANADA', 'SWITZERLAND', 'BOSNIA AND HERZEGOVINA', 'QATAR'
- **Groupe C** : 'BRAZIL', 'MOROCCO', 'SCOTLAND', 'HAITI'
- **Groupe D** : 'TURKEY', 'UNITED STATES', 'AUSTRALIA', 'PARAGUAY'
- **Groupe E** : 'GERMANY', 'ECUADOR', 'IVORY COAST', 'CURAÇAO'
- **Groupe F** : 'NETHERLANDS', 'JAPAN', 'SWEDEN', 'TUNISIA'
- **Groupe G** : 'BELGIUM', 'IRAN', 'EGYPT', 'NEW ZEALAND'
- **Groupe H** : 'SPAIN', 'URUGUAY', 'CAPE VERDE', 'SAUDI ARABIA'
- **Groupe I** : 'FRANCE', 'NORWAY', 'SENEGAL', 'IRAQ'
- **Groupe J** : 'ARGENTINA', 'AUSTRIA', 'ALGERIA', 'JORDAN'
- **Groupe K** : 'PORTUGAL', 'CONGO', 'COLOMBIA', 'UZBEKISTAN'
- **Groupe L** : 'ENGLAND', 'CROATIA', 'GHANA', 'PANAMA'

Les deux meilleures équipes de chaque groupe sont retenues pour la suite de la compétition.

12 Conclusion

Dans ce travail, nous avons étudié et comparé trois approches de modélisation pour la prédiction des résultats de la Coupe du Monde : un modèle basé sur les cotes Elo, un modèle probabiliste de type Poisson, et une version améliorée de ce dernier.

L'évaluation des modèles sur les données de la Coupe du Monde 2022 a permis de mettre en évidence les limites et les points forts de chaque approche. Le modèle Elo, bien que simple et rapide à mettre en œuvre, reste limité dans sa capacité à reproduire fidèlement les dynamiques des matchs. Le modèle de Poisson améliore la prise en compte du nombre de buts, mais ses performances restent variables selon les paramètres utilisés. Le modèle de Poisson amélioré obtient

globalement les meilleurs résultats, notamment sur le critère le plus important dans ce contexte : le taux de qualification.

Ce critère est en effet plus pertinent que l'accuracy seule, car l'objectif principal est de prédire correctement les équipes accédant à la phase à élimination directe plutôt que l'ordre exact de toutes les équipes.

Enfin, ce travail pourrait être amélioré en intégrant davantage de variables explicatives (forme récente des équipes, avantage du terrain, blessures) ou en utilisant des méthodes d'apprentissage automatique plus avancées afin de mieux capturer la complexité des rencontres internationales.

Références

- [1] Wikipedia contributors, *Elo rating system*, Disponible sur : https://en.wikipedia.org/wiki/Elo_rating_system (consulté en juin 2026).
- [2] Lorenz A. Gilch et Sebastian Müller, *On Elo Based Prediction Models for the FIFA World Cup 2018*, Article de recherche, 2018.